

Struktury kombinatoryczne w językach naturalnych

Projekt *Natural Languages*

czerwiec 2026

Streszczenie

Szukamy w słownikach i korpusie powtórzeń ukrytych w słowach: kwadratów, palindromów, kwadratów abelowych i przetasowanych kwadratów. Pytanie nie jest tylko teoretyczne — różne języki budują te struktury inaczej, więc liczby same w sobie opowiadają o morfologii. Dokument zbiera definicje, dwa krótkie lematy spinające parzystość z przetasowaniem, użyte algorytmy oraz wyniki dla czterech języków (PL, EN, DE, FR) i polskiego korpusu Wolnych Lektur.

1 Po co to

Słowo *kankan* to *kan* powtórzone dwa razy — kwadrat. *Kajak* czytany wstecz to wciąż *kajak* — palindrom. Takie struktury to klasa kombinatoryki na słowach (Lothaire, Crochemore–Rytter), ale w językach naturalnych są też *rzadkie*, a ich rekordy mówią coś o samym języku: niemiecki wygrywa złożeniami, polski i francuski fleksją. Inspiracją był artykuł prowadzącego (B. Pawlik, *The Secret Life of Words*, *Chalkdust*) oraz prace kolektywu TBN o przetasowanych kwadratach.

Projektowo trzymamy jedną zasadę: **diakrytyki to osobne symbole** (ą $\neq$ a). Normalizacja przed analizą to małe litery, bez interpunkcji i spacji.

2 Definicje

Definicja 1 (Kwadrat, sześcián, n -ta potęga). Kwadrat to słowo postaci ww (np. *kankan*); sześcián to www ; ogólnie n -ta potęga to w^n dla niepustego w .

Definicja 2 (Palindrom). Słowo równe swojemu odwróceniu, $w = \overleftarrow{w}$ (np. *kajak*).

Definicja 3 (Kwadrat abelowy). Słowo w_1w_2 , gdzie $|w_1| = |w_2|$ i w_2 jest anagramem w_1 (obie połowy mają ten sam multizbiór liter). Każdy kwadrat jest abelowy, ale nie odwrotnie.

Definicja 4 (Tangram). Słowo, w którym *każda* litera występuje parzystą liczbę razy. Pojęcie z artykułu prowadzącego; u nas pełni rolę taniego pre-filtru.

Definicja 5 (Przetasowany kwadrat). Słowo, które da się rozłożyć na dwa rozłączne, *równe* podciągi. Np. *abab* rozkłada się na *ab* (pozycje 0, 1) i *ab* (pozycje 2, 3). Nie mylić z kwadratem: kolejność liter może być przeplatana.

3 Galeria przykładów

Zanim przejdziemy do liczb – garść prawdziwych słów wyłowionych ze słowników (każde przeszło przez nasze detektory). Najlepiej widać tu charakter języków: angielski oszczędny, niemiecki długi przez złożenia, polski i francuski bogate w reduplikacje.

Kilka rzeczy, które bawią bardziej niż tabela:

- *couscous*, *froufrou* i *beriberi* są kwadratami ww **w kilku językach naraz** – zapożyczenia podróżują razem ze swoją strukturą.

	PL	EN	DE	FR
Palindrom	<i>kajak, anilina, owo-cowo, rotator, elemele, mellem, potop</i>	<i>kayak, radar, redder, tenet, civic, madam, minim</i>	<i>relieffeiler, rentner, retter, nennen, neo-zoen</i>	<i>ressasser, retâter, kayak, noyon, rotor</i>
Kwadrat <i>w</i> <i>w</i>	<i>kankan, niania, wszyscy, kuskus, dziadzia, psiapsia</i>	<i>cancan, murmur, tsetse, pompom, bonbon, muumuu</i>	<i>computercomputer, kleinklein, tamtam, plemplem, purpur</i>	<i>froufrou, chouchou, glouglou, gnangnan, ronron, tonton</i>
Sześcian <i>w</i> <i>w</i> <i>w</i>	<i>ajajaj, ojoj</i>	—	—	<i>blablabla</i>
Kwadrat abelowy	<i>niedziadzenia, kryptoportyk, niechachanie</i>	<i>teammate, signings, bilabial, beriberi</i>	<i>abtsstab, lauffaul, eins-sein, kleinklein</i>	<i>préimprimé, makémaké, naissain, coupecoupe</i>
Tangram	<i>niepoodpadanie, niechachanie, kryptoportyk, titicaca</i>	<i>senescence, tatlletale, caucasus, beriberi</i>	<i>frittierfett, mitmisst, speispinne, etheneinheit</i>	<i>concentrationnaire, collectionniste, intiment, regrattage</i>
Przetasowany kw.	<i>prepress, wszyscy, tatianin, titicaca</i>	<i>couscous, caucasus, beriberi, khoikhoi</i>	<i>computercomputer, kaukasus, plemplem</i>	<i>tuteurer, coupecoupe, chercher, titicaca</i>

Tabela 1: Przykłady słów dla każdej struktury w czterech językach.

- Niemieckie *generatorgenerator* to jednocześnie najdłuższy jednowyrazowy kwadrat i przetasowany kwadrat (18 liter) – czysto przez złożenie.
- Sześciany w obrębie jednego słowa prawie nie istnieją:** w całym polskim słowniku to tylko *ajajaj* i *ojoj*, po francusku *blablabla*. Trzy kopie z rzędu to dla języka naturalnego za dużo.
- prepress* (EN/PL) i *tuteurer* (FR) to klasyczne przetasowane kwadraty z artykułu prowadzącego; *tuteurer* = *tuer* przeplecione z *tuer*.
- intiment* (fr. „serdecznie”), *mitmisst* (niem. „współmierzy”) czy *senescence* to tangramy, które przy okazji są zwykłymi, sensownymi słowami.
- Sklejenia dwóch *sensownych* słów też bywają przetasowanymi kwadratami: ang. *angina + engine*, *average + verge*, *anaconda + coda*, *begin + begging* – z tego właśnie żyją rekordy (sekcja 7.2).

Każda struktura ma swoją paletę liter. Jeśli dla każdego słowa weźmiemy jego najdłuższy palindromiczny fragment i policzymy, jak często pojawiają się w nim poszczególne litery względem średniej w języku, wychodzi czytelny wzór: palindromy **lubią samogłoski** (A, E, O), a stronią od H, J, Q (rys. 1). Niemieckie palindromy kochają *E*, angielskie *I*. Rozbicie na struktury (rys. 2) pokazuje, że tangramy w polskim ciągną ku *V* i *B* (nazwy własne typu *vivienne*), a kwadraty *w**w* ku powtarzalnym sylabom.


4 Dwa lematy

Oba spinają parzystość z przetasowaniem i są bezpośrednim powodem, dla którego filtr tangramowy w ogóle działa.


Lemat 1. *Długość każdego tangramu jest parzysta.*

Dowód. Długość to suma licznosci wszystkich liter. Każdy składnik jest parzysty, więc suma też. □

Lemat 2 (przetasowany kwadrat $\Rightarrow$ tangram). *Jeśli s jest przetasowanym kwadratem, to każda litera występuje w s parzyście.*



Rysunek 1: Wzbogacenie liter w palindromicznych fragmentach względem średniej w języku (czerwień – częstsza, błękit – rzadsza).



Rysunek 2: Paleta liter czterech struktur w polskim słowniku.

Dowód. Z definicji s rozkłada się na dwa równe podciągi u i u . Litera c pojawia się w s tyle razy, ile w obu kopiach łącznie, czyli $2 \cdot (\text{liczność } c \text{ w } u)$ — liczba parzysta. $\square$

Implikacja nie odwraca się. Kontrprzykład: $abccba$ jest tangramem (każda litera dwa razy), ale nie jest przetasowanym kwadratem — żaden podział na dwa równe podciągi nie daje dwóch identycznych napisów. Dlatego tangram to warunek *konieczny*, nie wystarczający; służy do szybkiego odsiewania, po którym i tak trzeba uruchomić pełny test.

Sam test jest kosztowny nie przez przypadek: rozpoznawanie przetasowanego kwadratu jest NP-zupełne (Buss–Soltys 2014). To motywuje kaskadę *filtr parzystości* $\rightarrow$ *DFS* zamiast naiwnego przeglądu $\binom{n}{n/2}$ podziałów.

5 Algorytmy

Detektory (`detectors/`) pytają „czy *całe* słowo jest strukturą?”. Moduł `analysis/records.py` szuka *najdłuższego fragmentu* w tokenie lub zdaniu i jest dobrany pod skalę korpusu.

- **Palindrom** — Manacher, $O(n)$ (`longest_palindrome`). Strażniki między znakami ujednolicają parzystą i nieparzystą długość.
- **Kwadrat** — skan po okresie z wczesnym wyjściem: największe p , dla którego $s[i:i+p] = s[i+p:i+2p]$ (`longest_square`).

- **Kwadrat abelowy** — dwa sąsiednie okna długości L i toczący się wektor różnic licznosci, $O(1)$ na krok (`longest_abelian_square`).
- **Przetasowany kwadrat** — DFS z buforem FIFO i memoizacją po (pozycja, bufor), poprzedzony prefiltrem parzystości na maskach prefiksowych XOR (`is_shuffled_square`, `longest_shuffled_square`). Każdą literę przypisujemy do kopii „z przodu” (do bufora) albo „z tyłu” (musi zgodzić się z początkiem bufora). Limit długości okna chroni przed kosztem wykładniczym.
- **Sklejenia** — kubelki parzystości (`generative.py`). Skoro $\text{parity}(w_1w_2) = \text{parity}(w_1) \oplus \text{parity}(w_2)$, sklejenie jest tangramem dokładnie wtedy, gdy $\text{parity}(w_1) = \text{parity}(w_2)$. Grupuujemy słowa po masce i testujemy tylko pary w obrębie kubelka — dla PL to ~ 443 tys. par zamiast $\sim 10^{11}$.
- **Korpus** — branch-and-bound po długości malejąco plus round-robin na wielu rdzeniach (`examples/records.py`).

6 Dane i metodyka

6.1 Źródła i potok przygotowania

Słowniki bierzemy z hunspell LibreOffice (pobierane po HTTPS, więc skrypt działa tak samo na każdym systemie – nie sięga po lokalne `/usr/share/dict`). To **lematy** – formy hasłowe, nie odmienione. Wybór jest świadomy: ten sam typ danych z jednego źródła daje **uczciwe porównanie międzyjęzykowe**; ceną jest mniej kwadratów abelowych, niż dałaby pełna fleksja (patrz „Ograniczenia”). Korpus to próbka 25 MB Wolnych Lektur (PD / CC BY-SA).

Każde hasło przechodzi ten sam potok (`data/fetch.py`, `preprocessor.py`):

1. **dekodowanie** wg deklarowanego kodowania (PL ISO-8859-2, DE ISO-8859-1, EN/FR UTF-8), wyjście zawsze UTF-8;
2. odcięcie nagłówka z liczbą haseł i **flag afiksów** po znaku `/`;
3. odrzucenie haseł z **cyframi** (np. *1st*) i deduplikacja;
4. **normalizacja**: małe litery, regex zostawia tylko litery łacińskie wraz z diakrytykami – z zasadą projektową **ą** $\neq$ **a**: *q, ö, ç* to osobne symbole alfabetu, nie warianty.

Język	Hasła po normalizacji
polski (PL)	$\sim 302\,000$
niemiecki (DE)	$\sim 164\,000$
francuski (FR)	$\sim 79\,000$
angielski (EN)	$\sim 48\,000$

Tabela 2: Wielkość słowników po normalizacji.

6.2 Cztery soczewki poszukiwań

Tej samej struktury szukamy na czterech poziomach – każdy widzi co innego i ma własny sposób na ujarzmienie kosztu:

1. **Pojedyncze słowo** – czy całe hasło jest strukturą, oraz jego najdłuższy wewnętrzny fragment. Skala słownika, algorytmy z sekcji 5.


2. **Sklejenie dwóch słów** $w_1 + w_2$ – bo pojedyncze słowa rzadko są tangramami. Kubełki parzystości tną przegląd z $\sim 10^{11}$ do ~ 443 tys. par.
3. **Przez granice słów w zdaniu** – zdanie normalizujemy w całości (jak „*kobyła ma mały bok*”); branch-and-bound po długości + wiele rdzeni.
4. **Kolejne słowa realnego tekstu** – okna sąsiednich słów, więc wynik jest gramatyczny; filtr `is_repetition` odsiewa zwykłe powtórzenia.

Wspólny mianownik kosztowy: rozpoznanie przetasowanego kwadratu jest NP-zupełne, więc wszędzie stosujemy tę samą kaskadę **tani filtr parzystości (tangram) → kosztowny DFS**, a długości przeglądamy malejąco i wychodzimy na pierwszym trafieniu.

7 Wyniki

7.1 Rekordy w pojedynczych słowach

W obrębie jednego hasła wygrywa morfologia. Niemiecki króluje przez złożenia (*generatorgenerator* – kwadrat długości 18; palindrom *reliefffeiler*, 13). Polski daje kwadrat abelowy *niedziadzenia* (14), angielski *sensuousnes* (11) i *caucasus* (przetasowany kwadrat, 8), francuski *gagnantgagnant* (14). Najdłuższe jednowyrazowe przetasowane kwadraty: DE *generatorgenerator* (18), FR *gagnantgagnant* (14), PL *ościowościow* (12), EN *caucasus* (8). Zbiórzy „wyścig języków” (rys. 3) potwierdza wzorzec: niemiecki prawie zawsze najdłuższy (złożenia), polski bierze kwadrat abelowy (fleksja), angielski jest najkrótszy w każdej kategorii.



Rysunek 3: Najdłuższa struktura w pojedynczym słowie, per język i typ struktury.

7.2 Dwuwyrazowe przetasowane kwadraty


Skoro pojedyncze słowa rzadko są tangramami, prawdziwe rekordy mieszkają w sklejeniach dwóch różnych słów (wątek L. Mola i B. Pawlika). Tabela 3 i rysunek 4 pokazują, że ranking liczb to ranking bogactwa fleksji / złożień: francuski i polski na czele.

7.3 Przez granice słów w korpusie

Korpus przeszukujemy *zdaniami*: każde zdanie Wolnych Lektur normalizujemy (usuwamy spacje i interpunkcję) i szukamy najdłuższego fragmentu struktury **przez granice słów** – jak w szkolnym

Język	Liczba par	Rekord (znaki)	Przykład rekordu
FR	21 065	46	<i>lieutenantegouverneure + lieutenantesgouverneures</i>
PL	19 510	38	<i>dwudziestkadwójka + dwudziestkachdwójkach</i>
EN	5 895	26	—
DE	4 297	40	—

Tabela 3: Dwuwyrzowe przetasowane kwadraty. FR i PL dominują fleksją, DE łapie długość złoženiami mimo mniejszej liczby par.



Rysunek 4: Liczba dwuwyrzowych przetasowanych kwadratów w czterech językach.


„*kobyła ma mały bok*”. To 270 tys. zdań i tu, nie w słowniku, padają prawdziwe rekordy (rys. 7). Konkretnie:

- **Kwadrat *ww*, 66 znaków** – powtórzony wers z wiersza *Ćma*:
„*raz spojrzeć na mnie niebieską źrenicą*” $\times 2$. Poeta powtarza linijkę, więc po sklejeniu liter wychodzi czysty kwadrat.
- **Kwadrat *abelowy*, 72 znaki** – perełka, bo nie powtórzenie, lecz *lustrzane odbicie* z prawdziwej poezji:
„*mgła gęsta, ptak czarny, skrzydła białe, Boże | białe skrzydła, ptak czarny, mgła gęsta, Boże*”.
Druga połowa to anagram pierwszej – te same słowa w odwróconej kolejności.
- **Palindrom, 17 znaków** – i od razu morał: rekordem jest refren „*la la la...*”. Najdłuższy palindrom korpusu to artefakt, nie kunszt.


W sekwencjach *kolejnych słów* przetasowany kwadrat trafia na naturalny sufit ~ 34 znaki („*zgody lub niezgody humoru lub niehumoru*”) — granica nie algorytmiczna, lecz językowa: warunek tangramu jest tak ostry, że dłuższego sensownego ciągu po prostu nie ma. To ładne napięcie teoria $\leftrightarrow$ język: najdłuższy rekord bywa powtórzeniem, nie genuine przeplotem (odsiewa je filtr `is_repetition`).

A oto co skan korpusu naprawdę wyławia – genuine struktury w kolejnych słowach (nie powtórzenia), zwykle oparte na antytezie albo lustrze:

- **Przetasowane kwadraty** (antyteza): „*pogoda nie pogoda, choroba nie choroba*”, „*wiatrak nie wiatrak, wariat nie wariat*”, „*oko za oko, ząb za ząb*”, „*złamanie za złamanie, oko za oko*”.
- **Kwadraty *abelowe*** (chiasm): najpiękniejszy to „*czy ja piękny, a moja odpowiedź stosowna | czy ja stosowny, a moja odpowiedź piękna*” (66 znaków) – druga połowa to dokładny



Rysunek 5: Długość rekordowego sklejenia. DE wbija się wysoko mimo małej liczby par — to sygnatura złożień.



Rysunek 6: Rozkład długości sklejeń (PL) – masa wyników siedzi w krótkich parach, rekordy to długi ogon.

anagram pierwszej. Dalej „*od wschodu aż do zachodu | od zachodu aż do wschodu*” i „*z salonu do przedpokoju | z przedpokoju do salonu*”.


- **Palindromy frazowe:** „*jako lokaj*”, „*a to idiota*”, „*oko w oko*”, „*ram i mar*”.

8 Wydajność


Kaskada filtrów robi tu całą robotę. Przegląd korpusu (~ 270 tys. zdań) naiwnie trwałby ~ 5 min; branch-and-bound po długości ścina go do 82 s, a round-robin na 10 rdzeniach do **28 s**. Sklejenia całego słownika polskiego liczą się w **2,9 s** dzięki kubelkom parzystości — bez nich byłyby to kwadratowy przegląd $\sim 10^{11}$ par.

9 Ograniczenia

- **Lematy vs. formy odmienione.** Pracujemy na formach hasłowych. Pełna fleksja (Morfologik/SGJP dla PL, SCOWL/dwyl dla EN) dałaby istotnie więcej kwadratów abelowych; świadomie zostajemy przy lematach dla spójności PL $\leftrightarrow$ EN.



Rysunek 7: Najdłuższe struktury przez granice słów w korpusie Wolnych Lektur.



Rysunek 8: Struktury w sekwencjach kolejnych słów (frazy z korpusu).

- **NP-zupełność.** Przetasowany kwadrat ograniczamy długością okna; dla bardzo długich ciągów nie dajemy gwarancji wyczerpania.
- **Próbka korpusu.** 25 MB Wolnych Lektur, nie pełny zbiór — rekordy zdaniowe mogą jeszcze podrosnąć.
- **Powtórzenia.** Część rekordów zdaniowych to powtórzenia, nie genuine przeploty; filtrujemy je heurystyką, ale granica bywa nieostra.

Reprodukcja

```
make data
uv run python -m natural_languages.examples.records ...
uv run python -m natural_languages.examples.two_word_shuffle ...
uv run python -m natural_languages.examples.grammatical_shuffle ...
uv run python -m natural_languages.examples.dictionary_stats \
    --input data/raw/pl.txt --language pl
```

Liczby i wykresy pochodzą z notatników docs/*.ipynb (detectors, dictionaries, books, records); figury w docs/figures/ (PNG 300 dpi), tabele z CSV w results/.

Literatura

- [1] M. Lothaire. *Algebraic Combinatorics on Words*. Cambridge University Press, 2002.
- [2] M. Crochemore, W. Rytter. *Jewels of Stringology*. World Scientific, 2002.
- [3] B. Pawlik. *The Secret Life of Words*. Chalkdust.
- [4] Kolektyw TBN. *Przetasowane kwadraty 1–2*, 2024–2025.
- [5] A. Thue. *Über unendliche Zeichenreihen*, 1906.
- [6] V. Keränen. *Abelian squares are avoidable on 4 letters*, 1992.
- [7] S. Buss, M. Sołtys. *Unshuffling a square is NP-hard*, 2014.
- [8] L. Mol i in. Dwuwyrzowe przetasowane kwadraty.
- [9] OEIS, <https://oeis.org>.