

Struktury kombinatoryczne w językach naturalnych

Kwadraty, palindromy i przetasowania w słownikach i korpusie

Projekt *Natural Languages*

czerwiec 2026

kankan to *kan* dwa razy. *kajak* wspak to *kajak*. Takie powtórzenia ukryte w słowach to klasyka kombinatoryki na słowach — a w językach naturalnych są **rzadkie**, więc ich rekordy mówią coś o samym języku.

Teza

Ranking rekordów to ranking morfologii: niemiecki wygrywa **złożeniami**, polski i francuski **fleksją**.

Inspiracja: B. Pawlik, *The Secret Life of Words (Chalkdust)*; kolektyw TBN, *Przetasowane kwadraty*.

- **Kwadrat** — słowo postaci ww (*kankan*)
- **Palindrom** — równe swojemu odwróceniu (*kajak*)
- **Kwadrat abelowy** — w_1w_2 , gdzie w_2 jest anagramem w_1
- **Tangram** — każda litera występuje parzyście
- **Przetasowany kwadrat** — rozkłada się na dwa równe podciągi ($abab = ab \mid ab$)

Zasada projektowa

Diakrytyki to osobne symbole: $\text{ą} \neq \text{a}$. Normalizacja: małe litery, bez interpunkcji.

Palindromy

PL *kajak, anilina, owocowo, rotator, elemele, mełłem, potop*

EN *kayak, radar, redder, tenet, civic, madam, minim* DE *reliefpfeiler, rentner, nennen* FR *ressasser, retâter, noyon*

Kwadraty *ww*

PL *kankan, niania, wszywszy, kuskus, dziadzia, psiapsia*

EN *cancan, murmur, tsetse, pompom, bonbon, muumuu* DE *computercomputer, kleinklein, tamtam, purpur*

FR *froufrou, chouchou, glouglou, gnangnan, ronron, tonton*

Sześciany *www* — w jednym słowie prawie nie istnieją

PL *ajajaj, ojojaj* FR *blablabla* EN/DE —

Kwadraty abelowe

PL *niedziadzienia, kryptoportyk, niechachanie*

EN *teammate, signings, bilabial, beriberi* DE *abtsstab, lauffaul, einssein, kleinklein*

FR *préimprimé, makémaké, naissain, coupecoupe*

Tangramy (każda litera parzyście)

PL *niepoodpadanie, niechachanie, titicaca*

EN *senescence, tattletale, caucasus* DE *frittierfett, mitmisst, speispinne*

FR *concentrationnaire, collectionnite, intimement, regrattage*


Przetasowane kwadraty

PL *prepress, wszywszy, tatianin* EN *couscous, caucasus, beriberi, khoikhoi*

DE *computercomputer, kaukasus* FR *tuteurer, coupecoupe, chercher*

- *couscous, froufrou, beriberi* — kwadraty ww **w kilku językach naraz**; zapożyczenie wędruje ze swoją strukturą.
- *generatorgenerator* (DE) — najdłuższy jednowyrazowy kwadrat i przetasowany kwadrat (18 liter), czysto przez złożenie.
- *tuteurer* (FR) = *tuer* przeplecione z *tuer*; *prepress* (EN/PL) — klasyki przetasowanych kwadratów z artykułu.
- *intimement, mitmisst, senescence* — tangramy, które przy okazji są **normalnymi słowami**, nie tylko zabawkami.
- Sklejenia dwóch *sensownych* słów: ang. *angina+engine, average+verge, anaconda+coda, begin+begging*.

Które litery budują palindromy



Palindromy ciągną ku **samogłoskom** (A, E, O) i unikają spółgłosek typu H, J, Q. Niemieckie palindromy kochają *E*, angielskie *I*.

Słowniki hunspell (**lematy**, spójne między językami) + próbka 25 MB korpusu Wolnych Lektur.

Język	Hasła po normalizacji
polski (PL)	~302 000
niemiecki (DE)	~164 000
francuski (FR)	~79 000
angielski (EN)	~48 000

Ten sam potok dla każdego języka — żeby porównanie było uczciwe:

1. **pobranie** hunspell po HTTPS (działa na każdym systemie),
2. **dekodowanie** wg kodowania (PL 8859-2, DE 8859-1, EN/FR UTF-8) → UTF-8,
3. odcięcie **flag afiksów** (po /) i haseł z cyframi, deduplikacja,
4. **normalizacja**: małe litery, tylko litery + diakrytyki, $\text{ą} \neq \text{a}$.

Świadomie zostajemy przy **lematach** (formy hasłowe) — spójne między językami; ceną jest mniej kwadratów abelowych niż przy pełnej fleksji.

Trik, który to wszystko napędza

Lemat: przetasowany kwadrat $\Rightarrow$ tangram

Skoro s rozkłada się na dwie równe kopie u , każda litera występuje $2\times$ tyle, ile w u — parzyście. (Odwrotnie nie: $abccba$ to tangram, nie przetasowanie.)

Rozpoznanie przetasowanego kwadratu jest **NP-zupełne** (Buss–Sołtys 2014). Dlatego kaskada: **tani filtr parzystości** $\rightarrow$ kosztowny test (DFS z buforem FIFO).

Dla sklejeń: $\text{parity}(w_1 w_2) = \text{parity}(w_1) \oplus \text{parity}(w_2)$. Grupujemy słowa w **kubelki parzystości** — dla PL to ~ 443 tys. par zamiast $\sim 10^{11}$.

Cztery soczewki poszukiwań

Tej samej struktury szukamy na czterech poziomach — każdy widzi co innego:

1. **Pojedyncze słowo** — czy hasło jest strukturą + najdłuższy fragment w środku.
(skala słownika)
2. **Sklejenie dwóch słów** $w_1 + w_2$ — kubeczki parzystości tną 10^{11} par do ~ 443 tys.
(rekordy mieszkają tu)
3. **Przez granice słów w zdaniu** — całe zdanie bez spacji, jak „kobyła ma mały bok”.
(korpus, branch-and-bound)
4. **Kolejne słowa tekstu** — okna sąsiednich słów, więc wynik jest gramatyczny.
(chiazmy, antytezy)

Wspólny mianownik kosztu: wszędzie kaskada **filtr parzystości** $\rightarrow$ **DFS**, bo rozpoznanie przetasowanego kwadratu jest NP-zupełne.


Rekordy w pojedynczych słowach

W obrębie jednego hasła wygrywa morfologia.

Język	Rekord	Struktura (znaki)
DE	<i>generatorgenerator</i>	kwadrat / przetasowany (18)
PL	<i>niedziadzienia</i>	kwadrat abelowy (14)
FR	<i>gagnantgagnant</i>	przetasowany (14)
EN	<i>caucasus</i>	przetasowany (8)

DE króluje złożeniami (palindrom *reliefpfeiler*, 13); EN ma najkrótsze rekordy — uboga fleksja, brak złożień.


Wyścig języków



Niemiecki wygrywa prawie wszędzie (złożenia), **polski** bierze kwadrat abelowy (fleksja), **angielski** jest najkrótszy w każdej kategorii.

Dwuwyrazowe przetasowane kwadraty



Pojedyncze słowa rzadko są tangramami — rekordy mieszkają w **sklejeniach dwóch słów**.



Język	Par	Rekord
FR	21 065	46
PL	19 510	38
EN	5 895	26
DE	4 297	40

FR i PL na czele **fleksją**. Rekord FR:
lieutenantegouverneure
+ *lieutenantesgouverneures*.


Liczba kontra długość



Niemiecki ma mało par, ale **najdłuższe** — sygnatura złożień. Rozkład długości (PL): masa w krótkich parach, rekordy to długi ogon.

Przez granice słów w korpusie

270 tys. zdań Wolnych Lektur, struktura może przekraczać granice słów (jak „*kobyła ma mały bok*”). Prawdziwe rekordy padają tu, nie w słowniku:



Kwadrat 66 — powtórzony wers („Ćma”)

„raz spojrzeć na mnie niebieską źrenicą” ×2

Kwadrat abelowy 72 — lustro z poezji

*„mgła gęsta, ptak czarny, skrzydła białe, Boże |
białe skrzydła, ptak czarny, mgła gęsta, Boże”*

Palindrom 17 — i morał

rekord to refren „*la la la...*” — artefakt, nie kunszt

Gramatyczne perełki z korpusu

Autentyczne struktury w **kolejnych słowach** realnego tekstu — nie powtórzenia, lecz przeplecenia oparte na antytezie i lustrze:

Przetasowane kwadraty (antyteza)

„pogoda nie pogoda, choroba nie choroba” „wiatrak nie wiatrak, wariat nie wariat”
„oko za oko, ząb za ząb” „złamanie za złamanie, oko za oko”

Kwadraty abelowe (chiasm, lustro)

„czy ja piękny, a moja odpowiedź stosowna | czy ja stosowny, a moja odpowiedź piękna” (66)
„od wschodu aż do zachodu | od zachodu aż do wschodu” „z salonu do przedpokoju | z przedpokoju do salonu”
„sprzątanie i naprawy | naprawy i sprzątanie” „łzawą i zawiłą”

Palindromy frazowe

„jako lokaj” „a to idiota” „oko w oko” „ram i mar”

W sekwencjach *kolejnych słów* przetasowany kwadrat zatrzymuje się na ~ 34 znakach:

Rekord gramatyczny

„zgody lub niezgody humoru lub niehumoru”

To granica nie algorytmiczna, lecz **językowa** — warunek tangramu jest tak ostry, że dłuższego *sensownego* ciągu w naszej próbce po prostu nie znaleźliśmy. Napięcie teoria $\leftrightarrow$ język: najdłuższe rekordy bywają powtórzeniami, nie autentycznymi przeplotami.

Cała robota to kaskada filtrów.

Przegląd korpusu (~270 tys. zdań)	
naiwnie	~5 min
branch-and-bound (po długości)	82 s
+ 10 rdzeni (round-robin)	28 s
sklejenia całego słownika PL (kubeczki)	2,9 s

Liczby opowiadają o morfologii

DE — złożenia (długość). PL / FR — fleksja (liczba). EN — najuboższe rekordy.

Tani filtr parzystości robi z NP-zupełnego problemu coś policzalnego.